机器人带约束数值优化算法

从 Lagrange、KKT 到 QP、Active Set 与 Interior Point

系统学习笔记·机器人优化与控制方向

2026 年 10 月

摘要

本文总结机器人带约束连续优化的核心框架：数学建模、拉格朗日乘子与 KKT 条件、凸二次规划（QP）的求解、Primal Active Set 的工作集更新与步长推导、对数障碍和原始–对偶内点法、以及机械臂逆运动学、全身控制（WBC）和模型预测控制（MPC）中的建模方法。重点关注公式从何而来、算法为何正确、实践中容易犯什么错误。

目录

1 问题总览：机器人为什么需要约束优化？ 4

1.1 常见问题与算法的层次 4

2 其它约束优化工具：投影法、罚函数与增广拉格朗日 4

2.1 Projected Gradient：先下降再投影 4

2.2 Penalty Method：把约束违反写进目标 5

2.3 Augmented Lagrangian：乘子加罚项 5

2.4 三者与硬约束 QP 的区别 5

3 拉格朗日乘子法：从约束几何到代数方程 5

3.1 为什么最优点的梯度不必为零? 5

3.2 等式约束 Lagrange 条件 6

3.3 Lagrange 条件是方程，不自动保证极小值 6

3.4 从 KKT 方程到 Newton 方程 6

4 KKT：同时处理等式与不等式约束 7

4.1 四类条件 7

4.2 有效约束与互补松弛 7

4.3 约束资格条件与凸性 7

4.4 乘子的两种解释 8

5 QP 的定义、凸性和相关问题 8

5.1 标准形式与 Hessian 8

5.2 与 LP、最小二乘、QCQP 的关系 8

5.3 几何解释：加权投影 8

6 等式约束 QP：线性方程、Schur 补和零空间法 9

6.1 直接求解 KKT 系统 9

6.2 Schur 补推导 9

6.3 零空间法：约束消元 9

7 一般 QP 的 KKT 与全局最优性 10

7.1 一个完整二维 QP 10

7.2 QP 的对偶形式和互补间隙 11

8 Primal Active Set：可行有效集法 11

8.1 出发点：互补条件中的未知选择 11

8.2 如何选择初始点和初始工作集? 11

8.3 工作集子问题与 KKT 方向 12

8.4 为何最大理想步长 $\alpha = 1$? 12

8.5 Ratio Test：不能穿越非有效约束 13

8.6 为什么方向为零时可能还不能停止? 13

8.7 Active Set 伪代码 13

8.8 手算完整过程 13

9 Interior Point：障碍函数与中心路径 14

9.1 与 Active Set 的思想差异 14

9.2 Log Barrier（对数障碍） 14

9.3 障碍函数梯度与 Hessian 14

9.4 一维中心路径解析例子 14

9.5 障碍函数为什么对应扰动 KKT? 15

10 Primal-Dual Interior Point：牛顿求解扰动 KKT 15

10.1 原始–对偶变量及残差 15

10.2 Newton 线性化：原始–对偶 KKT 系统 15

10.3 消元获得更小的线性系统 15

10.4 步长和中心化参数 16
10.5 Infeasible Start 的含义 16

11 Active Set、Interior Point 与其他方法对比 16

12 其它迭代框架：SQP、SCP 与 ADMM 17
12.1 SQP：非线性优化外层每次求一个 QP 17
12.2 Sequential Convex Programming（SCP）：局部凸化非凸约束 17
12.3 ADMM：用增广拉格朗日分裂变量 17

13 机器人建模：从物理方程到 QP 18
13.1 实例一：带关节限位的速度逆运动学 18
13.2 实例二：机器人全身控制 WBC 18
13.3 实例三：线性 MPC 19
13.4 实例四：SQP 为什么会反复调用 QP? 19

14 实现、数值稳定性与高频易错点 19
14.1 数值实现检查清单 19
14.2 易错点总表 20

15 编程模板：CVXPY 验证 QP 与 KKT 20

16 练习题（从理论到机器人应用） 21

17 最后的知识脉络 21

1 问题总览：机器人为什么需要约束优化?

机器人优化变量可能是关节角 q、关节速度 $\dot{q}$、广义加速度 $\ddot{q}$、驱动力矩 τ、接触力 f_c、整段状态和控制轨迹等。一般问题写作

$$\boxed{\begin{aligned} \min_{x\in\mathbb{R}^n} \quad & f(x) \\ \text{s.t.} \quad & h(x)=0, \\ & g(x)\le 0, \\ & \ell \le x \le u. \end{aligned}} \tag{1}$$

等式约束可表示运动学闭链、离散动力学、接触不滑动；不等式可表示关节限位、力矩限制、摩擦锥线性近似、安全裕量等。最优点通常**不满足** $\nabla f(x^*)=0$，因为目标函数想继续下降的方向可能被约束阻挡。

1.1 常见问题与算法的层次

概念	数学角色	机器人例子
LP	线性目标、仿射约束	可行性子问题、资源分配
QP	二次目标、仿射约束	速度 IK、线性 MPC、WBC
NLP	一般非线性目标和约束	非线性轨迹优化
KKT	最优性条件（不是求解器）	判定候选点的驻点/互补性
Active Set	根据有效约束求解 QP	小中型、可热启动 QP
Interior Point	扰动互补条件/障碍路径	稀疏大型 QP 和 NLP
SQP	NLP 的外层算法，每步解 QP	非线性 MPC / 轨迹优化
SCP	逐次构造凸近似问题	非凸避障轨迹优化
Augmented Lagrangian	乘子与罚项结合	一般等式约束优化
ADMM	算子分裂与交替更新	结构化/分布式 QP

重要区别：**QP 是问题类型；KKT 是条件；Active Set 和 Interior Point 是求解方法；SQP 是将 NLP 迭代近似为 QP 的算法**。

2 其它约束优化工具：投影法、罚函数与增广拉格朗日

2.1 Projected Gradient：先下降再投影

对简单闭凸集 C 上的约束问题 $\min_{x\in C} f(x)$，投影梯度法写为

$$\boxed{x_{k+1}=\Pi_C\big(x_k-\alpha_k\nabla f(x_k)\big),\quad \Pi_C(y)=\arg\min_{z\in C}\frac{1}{2}\|z-y\|^2.} \tag{2}$$

对于盒约束 $\ell\le x\le u$，投影只需逐元素截断 $\Pi_C(y)_i=\min\{u_i,\max\{\ell_i,y_i\}\}$；但对复杂机器人运动学或接触约束，投影本身可能就是一个复杂的优化问题。当集合凸且目标凸且满足合适步长条件时，可以分析其收敛性；在非凸机器人约束上不能直接照搬这些保证。

2.2 Penalty Method：把约束违反写进目标

考虑等式约束 $h(x)=0$，二次罚函数为

$$\boxed{F_\rho(x)=f(x)+\frac{\rho}{2}\left\|h(x)\right\|^2,\qquad \rho>0.} \tag{3}$$

对 $g_i(x)\le 0$，可加入 $\frac{\rho}{2}\sum_i \max\{0,g_i(x)\}^2$。这样可以复用无约束 Newton、BFGS 或 L-BFGS。缺点是有限 ρ 往往只能近似满足约束；若为了高精度把 ρ 取很大，Hessian 的条件数可能严重恶化。

机器人示例 对末端位置要求 $p(q_T)=p_d$，可以优化

$$\min_{q_{0:T}} \sum_{k=0}^{T-1}\left\|q_{k+1}-q_k\right\|^2+\frac{\rho}{2}\left\|p(q_T)-p_d\right\|^2.$$

这类软约束更容易建模，但不能保证有限权重下末端误差精确为零。

2.3 Augmented Lagrangian：乘子加罚项

纯罚函数的病态问题可以通过增广拉格朗日缓解。对 $h(x)=0$，定义

$$\boxed{\mathcal{L}_\rho(x,\nu)=f(x)+\nu^{\mathsf{T}}h(x)+\frac{\rho}{2}\left\|h(x)\right\|^2.} \tag{4}$$

经典的乘子更新为

$$\boxed{\begin{aligned} &x_{k+1}\approx \arg\min_x \mathcal{L}_\rho(x,\nu_k),\\ &\nu_{k+1}=\nu_k+\rho\,h(x_{k+1}). \end{aligned}} \tag{5}$$

这里内部优化不一定要每步精确求解。相比单纯增加罚权重，乘子迭代可在适当正则性和求解精度条件下，用有限的惩罚参数得到高约束精度。对于不等式，可结合非负乘子的投影更新或使用等价的 ALM 形式；不应直接把等式更新不加修改地套到所有不等式上。

2.4 三者与硬约束 QP 的区别

投影法明确返回可行集中的点（在投影能够精确求解时）；罚函数和增广拉格朗日通过目标或乘子机制处理约束；标准 QP 则显式保留硬线性约束并可直接利用 KKT、Active Set 或 Interior Point。如何选择取决于约束结构、实时性、可行性要求和模型非线性程度。

3 拉格朗日乘子法：从约束几何到代数方程

3.1 为什么最优点的梯度不必为零?

考虑

$$\min_{x,y}\ x^2+y^2,\qquad \text{s.t. } x+y=1.$$

唯一最优点为 $(\frac{1}{2},\frac{1}{2})$，但 $\nabla f=(1,1)^{\mathsf T}\neq 0$。沿着约束直线允许的切向方向 v 满足

$$\nabla h(x)^{\mathsf T}v=0,\qquad h(x,y)=x+y-1.$$

在正则的局部极小点上，对于每一个可行切向方向有 $\nabla f(x^*)^{\mathsf T}v=0$，所以 $\nabla f(x^*)$ 必须落在约束法向量张成的空间内。

3.2 等式约束 Lagrange 条件

设 $h:\mathbb{R}^n\to\mathbb{R}^m$，构造

$$\mathcal{L}(x,\nu)=f(x)+\nu^{\mathsf T}h(x),\qquad \nu\in\mathbb{R}^m. \tag{6}$$

令 $J_h(x)=\partial h/\partial x\in\mathbb{R}^{m\times n}$，在等式约束 Jacobian 满行秩等适当正则性条件下，局部最优点满足

$$\boxed{\nabla f(x^*)+J_h(x^*)^{\mathsf T}\nu^*=0,\qquad h(x^*)=0.} \tag{7}$$

几何上，$\ker J_h$ 是约束的切空间，而 $\mathrm{Im}(J_h^{\mathsf T})=(\ker J_h)^{\perp}$。式 (7) 表达了目标梯度与约束法向量的平衡。

例题 对 $\min(x^2+y^2)$ 且 $x+y=1$，写出

$$\mathcal{L}=x^2+y^2+\nu(x+y-1),\quad 2x+\nu=0,\ 2y+\nu=0,\ x+y=1.$$

求得 $x^*=y^*=1/2$、$\nu^*=-1$。乘子符号依赖约束和 Lagrangian 的书写约定。

3.3 Lagrange 条件是方程，不自动保证极小值

无约束的 $f(x)=-x^2$ 在 $x=0$ 满足驻点条件，却是最大值。对有约束的问题也必须考虑凸性或二阶充分条件，不能把求得的 Lagrange 方程解直接称作最优解。

3.4 从 KKT 方程到 Newton 方程

等式约束 NLP 的最优性方程为

$$F(x,\nu)=\begin{bmatrix}\nabla_x\mathcal{L}(x,\nu)\\ h(x)\end{bmatrix}=0.$$

对 (x,ν) 做 Newton 线性化：

$$\boxed{\begin{bmatrix}\nabla^2_{xx}\mathcal{L} & J_h^{\mathsf T}\\ J_h & 0\end{bmatrix}\begin{bmatrix}\Delta x\\ \Delta\nu\end{bmatrix}=-\begin{bmatrix}\nabla_x\mathcal{L}\\ h(x)\end{bmatrix}.} \tag{8}$$

这类分块矩阵称为 KKT（或鞍点）矩阵；它通常**不定**，不能因左上角正定就直接对整块矩阵做 Cholesky 分解。实际算法还需要步长、信赖域或正则化以增强鲁棒性。

4 KKT：同时处理等式与不等式约束

4.1 四类条件

考虑 $\min f(x)$，满足 $h(x)=0$ 与 $g(x)\le 0$，构造

$$\mathcal{L}(x,\nu,\lambda)=f(x)+\nu^{\mathsf{T}}h(x)+\lambda^{\mathsf{T}}g(x).$$

对应 KKT 条件为

$$\boxed{\begin{array}{ll}\nabla f(x^*)+J_h(x^*)^{\mathsf{T}}\nu^*+J_g(x^*)^{\mathsf{T}}\lambda^*=0 & \text{驻点条件,}\\ h(x^*)=0,\quad g(x^*)\le 0 & \text{原始可行,}\\ \lambda^*\ge 0 & \text{对偶可行,}\\ \lambda_i^* g_i(x^*)=0\quad(\forall i) & \text{互补松弛.}\end{array}} \tag{9}$$

必须强调：这里使用的是最小化和 $g_i(x)\le 0$ 约定，故不等式乘子取 $\lambda_i\ge 0$；等式乘子 ν_i 不受符号限制。

4.2 有效约束与互补松弛

定义有效约束集合 $\mathcal{A}(x)=\{i:g_i(x)=0\}$。由 $\lambda_i g_i(x)=0$ 得：

$$g_i(x)<0\Longrightarrow\lambda_i=0,\qquad \lambda_i>0\Longrightarrow g_i(x)=0.$$

反命题不成立：若 $g_i(x)=0$，其乘子可能等于零；这叫退化有效约束的常见现象。

一维例题 对 $\min(x-2)^2$，约束 $x\le 1$，有

$$\mathcal{L}=(x-2)^2+\lambda(x-1),\quad 2(x-2)+\lambda=0.$$

最优点 $x^*=1$，乘子 $\lambda^*=2>0$。沿 $+x$ 方向目标还想下降，但约束禁止这种移动。

4.3 约束资格条件与凸性

对一般 NLP，局部最优点满足 KKT 通常需要约束资格条件，例如 LICQ、MFCQ。LICQ 要求有效不等式约束与等式约束的梯度线性独立。凸优化中经常使用 Slater 条件保证适当的强对偶/KKT 必要性结论。

定理 4.1 (凸问题的 KKT 充分性)**.** 若 f 和所有 g_i 为凸函数、等式约束 h 为仿射函数，且有一组原始/对偶变量满足 *KKT*，那么其中的 x^* 是全局最优解。

这一定理不要求先证明某个约束资格条件，因为这里已经假设 *KKT* 乘子存在。约束资格条件更多是在保证最优点处存在这样的乘子。

4.4 乘子的两种解释

灵敏度：对 $h(x)=b$，如果最优值函数 $V(b)$ 可微且满足相应正则性条件，使用 $\mathcal{L}=f+\nu^{\mathsf{T}}(h-b)$，有

$$\frac{\partial V}{\partial b}=-\nu^{*}.$$

不等式 $G_i x\le d_i$ 的最优值关于 d_i 的局部变化率通常是 $-\lambda_i^{*}$。乘子因此常称为影子价格。

力学：在约束机械系统中，约束广义力往往写成 $J_c(q)^{\mathsf{T}}f_c$。形式上与 $J_h^{\mathsf{T}}\nu$ 相同，但一般优化问题的乘子并不自动具有物理力单位或物理力意义。

5 QP 的定义、凸性和相关问题

5.1 标准形式与 Hessian

$$\boxed{\begin{aligned}\min_{x\in\mathbb{R}^n}\quad & \tfrac{1}{2}x^{\mathsf{T}}Hx+c^{\mathsf{T}}x\\ \text{s.t.}\quad & Ax=b,\\ & Gx\le d,\end{aligned}}\qquad H=H^{\mathsf{T}}. \tag{10}$$

目标函数梯度与 Hessian：

$$\nabla f(x)=Hx+c,\qquad \nabla^2 f(x)=H.$$

$H\succeq 0$ 时为凸 QP；$H\succ 0$ 时目标严格凸，若可行域非空则最优解存在且唯一。$H\succeq 0$ 但奇异时，可能有多个最优解，甚至在无界可行域上出现目标无下界的情况。H 不定时是非凸 QP，KKT 不再确保全局最优。

5.2 与 LP、最小二乘、QCQP 的关系

$H=0$ 时 QP 退化为 LP。线性最小二乘

$$\min_x \tfrac{1}{2}\left\|Jx-e\right\|^2=\min_x\left(\tfrac{1}{2}x^{\mathsf{T}}J^{\mathsf{T}}Jx-(J^{\mathsf{T}}e)^{\mathsf{T}}x\right)+\text{常数}$$

属于凸 QP，其参数为 $H=J^{\mathsf{T}}J\succeq 0$、$c=-J^{\mathsf{T}}e$。加入 $\frac{\rho}{2}\left\|x\right\|^2$ 后，$H=J^{\mathsf{T}}J+\rho I\succ 0$（$\rho>0$）。

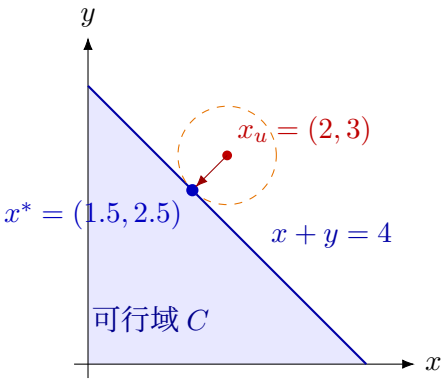
QCQP 允许二次约束 $x^{\mathsf{T}}Qx\le r$，一般不是标准 QP。QP 要求约束仿射（如 $Ax=b, Gx\le d$），即便其目标函数是二次的。

5.3 几何解释：加权投影

当 $H\succ 0$，令无约束最优点 $x_u=-H^{-1}c$。通过配方：

$$f(x)=\tfrac{1}{2}(x-x_u)^{\mathsf{T}}H(x-x_u)+\text{常数}.$$

因此凸约束 QP 可视为在 H-加权度量下，把 x_u 投影到多面体可行域 $C=\{x: Ax=b,\ Gx\le d\}$ 上。



该示意图对应 $\min (x-2)^2 + (y-3)^2$，满足 $x + y \le 4$、$x \ge 0$、$y \ge 0$。结果是 $x^* = (1.5, 2.5)$。

6 等式约束 QP：线性方程、Schur 补和零空间法

6.1 直接求解 KKT 系统

对于

$$\min_x \tfrac{1}{2} x^\mathsf{T} H x + c^\mathsf{T} x, \qquad Ax = b,$$

Lagrangian 为 $\mathcal{L} = \frac{1}{2} x^\mathsf{T} H x + c^\mathsf{T} x + \nu^\mathsf{T}(Ax - b)$。KKT 为

$$\boxed{\begin{bmatrix} H & A^\mathsf{T} \\ A & 0 \end{bmatrix} \begin{bmatrix} x \\ \nu \end{bmatrix} = \begin{bmatrix} -c \\ b \end{bmatrix}.} \tag{11}$$

若 $H \succ 0$ 且 A 行满秩，则该 KKT 矩阵非奇异。实际程序用线性方程组求解器（如对称不定分解 LDL^T），**不要显式计算矩阵逆**。

6.2 Schur 补推导

由 $Hx + c + A^\mathsf{T}\nu = 0$ 得 $x = -H^{-1}(c + A^\mathsf{T}\nu)$，再代入 $Ax = b$：

$$\boxed{(AH^{-1}A^\mathsf{T})\nu = -(b + AH^{-1}c).} \tag{12}$$

解出 ν 后回代 x。这在 $m \ll n$ 且 H 易于线性求解时很有效；公式中的 H^{-1} 只表示理论上的线性算子，不建议在代码中显式形成逆矩阵。

6.3 零空间法：约束消元

设 x_p 满足 $Ax_p = b$，Z 的列构成 $\mathrm{Null}(A)$ 的一组基，即 $AZ = 0$，则所有等式可行点为 $x = x_p + Zz$。代回目标函数得到

$$\min_z \ \tfrac{1}{2} z^\mathsf{T}(Z^\mathsf{T} H Z) z + [Z^\mathsf{T}(Hx_p + c)]^\mathsf{T} z.$$

于是

$$\boxed{(Z^\mathsf{T} H Z) z^* = -Z^\mathsf{T}(Hx_p + c), \qquad x^* = x_p + Zz^*.} \tag{13}$$

即便 H 只半正定，只要在可行切空间上 $Z^\mathsf{T} H Z \succ 0$，仍可拥有唯一的约化最优点。这是**约化 Hessian** 的基本思想。

与机器人 Jacobian 伪逆的联系 对于 $\min_{\Delta q} \frac{1}{2}\|\Delta q\|^2$，约束 $J\Delta q = e$，若 J 行满秩，则

$$\boxed{\Delta q = J^{\mathsf{T}}(JJ^{\mathsf{T}})^{-1}e = J^{\dagger}e.}$$

所以最小范数伪逆 IK 可以直接从等式约束 QP 推导出来。

7 一般 QP 的 KKT 与全局最优性

对式 (10)，定义等式乘子 $\nu \in \mathbb{R}^m$ 和不等式乘子 $\lambda \in \mathbb{R}^p_{\geq 0}$，有

$$\boxed{\begin{aligned} &Hx + c + A^{\mathsf{T}}\nu + G^{\mathsf{T}}\lambda = 0, \\ &Ax = b, \quad Gx \leq d, \\ &\lambda \geq 0, \\ &\lambda_i(G_i x - d_i) = 0 \quad \forall i. \end{aligned}} \tag{14}$$

定义松弛变量 $s = d - Gx \geq 0$，互补条件变为 $s_i\lambda_i = 0$。

定理 7.1 (凸 QP：KKT 的充分性)**.** 当 $H \succeq 0$ 时，任何满足式 (14) 的点 x^* 均是全局最优解。

证明思路： 取任一可行 y，利用二次函数精确展开，

$$\begin{aligned} f(y) - f(x^*) = \nabla f(x^*)^{\mathsf{T}}(y - x^*) \\ + \tfrac{1}{2}(y - x^*)^{\mathsf{T}}H(y - x^*). \end{aligned}$$

利用驻点与等式约束，右侧第一项等于 $-\lambda^{*\mathsf{T}}(Gy - d) \geq 0$，第二项因 $H \succeq 0$ 也非负，故 $f(y) \geq f(x^*)$。 □

7.1 一个完整二维 QP

$$\boxed{\begin{aligned} \min_{x,y} \quad & (x-2)^2 + (y-3)^2 \\ \text{s.t.} \quad & x + y \leq 4, \quad x \geq 0, \quad y \geq 0. \end{aligned}} \tag{15}$$

取 $z = (x, y)^{\mathsf{T}}$，对应 $H = 2I$、$c = (-4, -6)^{\mathsf{T}}$，并忽略原目标中的常数 13：

$$G = \begin{bmatrix} 1 & 1 \\ -1 & 0 \\ 0 & -1 \end{bmatrix}, \qquad d = \begin{bmatrix} 4 \\ 0 \\ 0 \end{bmatrix}.$$

原始目标的无约束最优点为 $(2, 3)$，它不满足 $x + y \leq 4$。假设第一条不等式有效，另两条非有效：

$$2(x-2) + \lambda_1 = 0, \quad 2(y-3) + \lambda_1 = 0, \quad x + y = 4.$$

得到 $x^* = 1.5$、$y^* = 2.5$、$\lambda^* = (1, 0, 0)^{\mathsf{T}}$。其余约束严格满足，故满足 KKT，因 $H = 2I \succ 0$，这是唯一全局最优点。**原目标值**为 0.5；删除常数 13 后的标准 QP 目标值是 -12.5。

7.2 QP 的对偶形式和互补间隙

当 $H \succ 0$，令 $w = c + A^{\mathsf{T}}\nu + G^{\mathsf{T}}\lambda$。对 x 最小化 Lagrangian 后，得到对偶函数

$$q(\nu, \lambda) = -\tfrac{1}{2} w^{\mathsf{T}} H^{-1} w - b^{\mathsf{T}}\nu - d^{\mathsf{T}}\lambda,$$

对偶问题为 $\max_{\nu,\lambda\geq 0} q(\nu, \lambda)$。若原始变量可行、对偶乘子可行且满足驻点条件，原始与对偶目标间隙为

$$\boxed{f(x) - q(\nu, \lambda) = \lambda^{\mathsf{T}} s.} \tag{16}$$

如果当前驻点残差未归零，不能把 $\lambda^{\mathsf{T}} s$ 不加条件地当作精确目标差。

8 Primal Active Set：可行有效集法

8.1 出发点：互补条件中的未知选择

QP 的 $s_i\lambda_i = 0$ 表示每个约束都要决定究竟是 $s_i = 0$（可能有效），还是 $\lambda_i = 0$（乘子为零）。Primal Active Set 维护一个工作集 $\mathcal{W}_k$，把其中不等式当作等式，且**迭代的原始变量始终可行**。

8.2 如何选择初始点和初始工作集?

要求

$$\boxed{Ax_0 = b, \quad Gx_0 \leq d.}$$

可以选任意可行点；初始工作集是 $G_i x_0 = d_i$ 的一部分或全部（通常要求其约束梯度与等式约束一起线性独立）。例如式 (15) 的 $(0, 0)$、$(1, 1)$、$(2, 2)$ 都可行，但初始工作集分别不同。

找不到可行点：Phase I 若 $Ax = b$ 一致，可先解线性规划

$$\boxed{\begin{aligned} \min_{x,t} \quad & t \\ \text{s.t.} \quad & Ax = b, \\ & Gx \leq d + t\mathbf{1}, \\ & t \geq 0. \end{aligned}} \tag{17}$$

当其最优目标 $t^* = 0$ 时，得到原问题的可行点；若 $t^* > 0$，则原问题约束不可同时满足。若 $Ax = b$ 本身不一致，(17) 甚至无可行点，需对等式引入人工变量或先检查一致性。

一致性判据 $Ax = b$ 有解当且仅当

$$\boxed{\operatorname{rank}(A) = \operatorname{rank}([A \mid b]).}$$

例如 $x + y = 1$、$2x + 2y = 3$ 互相矛盾；但 $x + y = 1$、$2x + 2y = 2$ 仅仅冗余。**等式单独可行**也不能保证结合 $Gx \leq d$ 后整体可行。

热启动 在重复求解的 MPC 中，可以尝试继承前一次的解和有效集，但上次解对新约束不一定可行，Primal Feasible 版本必须先检查或修复可行性；另外还有 Dual Active Set 之类的替代初始化策略。

8.3 工作集子问题与 KKT 方向

在可行 x_k 上，令

$$B_k = \begin{bmatrix} A \\ G_{\mathcal{W}_k} \end{bmatrix}, \qquad B_k p = 0.$$

目标函数的精确二次展开为

$$f(x_k + p) = f(x_k) + \nabla f(x_k)^{\mathsf{T}} p + \tfrac{1}{2} p^{\mathsf{T}} H p.$$

所以工作集方向由以下等式约束 QP 给出：

$$\min_{p} \ \tfrac{1}{2} p^{\mathsf{T}} H p + \nabla f(x_k)^{\mathsf{T}} p, \qquad B_k p = 0.$$

求解 KKT 系统：

$$\boxed{\begin{bmatrix} H & B_k^{\mathsf{T}} \\ B_k & 0 \end{bmatrix} \begin{bmatrix} p_k \\ \eta_k \end{bmatrix} = \begin{bmatrix} -\nabla f(x_k) \\ 0 \end{bmatrix}.} \tag{18}$$

这里暂设 $H \succ 0$、B_k 行满秩，保证子问题方向唯一且线性系统非奇异。

8.4 为何最大理想步长 $\alpha = 1$?

沿当前方向定义 $\phi(\alpha) = f(x_k + \alpha p_k)$，精确展开：

$$\phi(\alpha) = f(x_k) + \alpha \nabla f(x_k)^{\mathsf{T}} p_k + \tfrac{1}{2} \alpha^2 p_k^{\mathsf{T}} H p_k.$$

由式 (18) 的驻点方程左乘 p_k^{T}，且 $B_k p_k = 0$，有

$$\boxed{\nabla f(x_k)^{\mathsf{T}} p_k = -p_k^{\mathsf{T}} H p_k.} \tag{19}$$

于是

$$\phi'(\alpha) = (\alpha - 1) p_k^{\mathsf{T}} H p_k,$$

当 $p_k \neq 0$ 且 $H \succ 0$，沿直线方向的唯一最优步长就是 $\boxed{\alpha^* = 1}$。这**不是人为选择的常数**，而是精确解工作集 QP 的结果。

进一步：

$$\boxed{f(x_k + \alpha p_k) - f(x_k) = -(\alpha - \tfrac{1}{2}\alpha^2) p_k^{\mathsf{T}} H p_k.}$$

对 $0 < \alpha \leq 1$，严格下降。因此只要不违反其他约束，越接近 $\alpha = 1$ 越好。

8.5 Ratio Test：不能穿越非有效约束

对 $i \notin \mathcal{W}_k$，若 $G_i p_k > 0$，需要

$$G_i(x_k + \alpha p_k) \le d_i \Longleftrightarrow \alpha \le \frac{d_i - G_i x_k}{G_i p_k}.$$

因此最大允许步长为

$$\boxed{\alpha_k = \min\left\{1,\ \min_{\substack{i \notin \mathcal{W}_k \\ G_i p_k > 0}} \frac{d_i - G_i x_k}{G_i p_k}\right\}.} \tag{20}$$

没有可能阻挡方向的约束时，内层最小值视为 $+\infty$。若 $\alpha_k < 1$，到达某个阻挡边界，把相应约束加入工作集；若 $\alpha_k = 1$，完整走到当前工作集子问题的最优点。

8.6 为什么方向为零时可能还不能停止?

若 $p_k = 0$，说明固定当前工作集后不能继续下降；但该集合可能错误。取式 (18) 得到的有效不等式乘子：

- 若全部 $\lambda_i \ge 0$，连同原始可行性即构成完整 KKT，凸 QP 可终止。
- 若存在 $\lambda_i < 0$，删除一个负乘子对应的不等式约束（常删最负者），再次求方向。

原始等式约束不能因为乘子为负就删除。有效约束在最优点的乘子允许恰好为零。

8.7 Active Set 伪代码

1. 寻找可行点 x_0，选择独立的初始工作集 $\mathcal{W}_0$。
2. 解工作集方向 QP，获得 p_k 和乘子。
3. 如果 $p_k \neq 0$：根据式 (20) 取最大可行步长，更新 x；若遇到阻挡约束，则加入工作集。
4. 如果 $p_k = 0$：检查有效不等式乘子；都非负则终止，否则删除一个负乘子约束。
5. 重复步骤 2–4。

要点： 上述是教学用的原始可行 Active Set。在退化工作集、线性相关约束、有限精度、半正定 Hessian 等情形需要防循环、秩揭示、正则化和容差策略。

8.8 手算完整过程

再次考虑式 (15)，记三个约束为

$$g_1 = x + y - 4 \le 0, \quad g_2 = -x \le 0, \quad g_3 = -y \le 0.$$

从 $z_0 = (0,0)$ 开始，初始工作集 $\mathcal{W}_0 = \{g_2, g_3\}$。

阶段	当前点 (x,y)	工作集	计算与动作
0	$(0,0)$	$\{g_2,g_3\}$	$p=0$，乘子 $\lambda_2=-4,\lambda_3=-6$，删 g_3。
1	$(0,0)$	$\{g_2\}$	$p=(0,3)$，$\alpha=1$，移动到 $(0,3)$。
2	$(0,3)$	$\{g_2\}$	$p=0$，乘子 $\lambda_2=-4$，删 g_2。
3	$(0,3)$	$\varnothing$	$p=(2,0)$；g_1 阻挡，Ratio $=(4-3)/2=1/2$，到 $(1,3)$，加 g_1。
4	$(1,3)$	$\{g_1\}$	$p=(1/2,-1/2)$，$\alpha=1$，到 $(1.5,2.5)$。
5	$(1.5,2.5)$	$\{g_1\}$	$p=0$，$\lambda_1=1\ge 0$；终止。

这里算法既出现了删除工作集约束，也出现了新增阻挡约束；两种机制缺一不可。

9 Interior Point：障碍函数与中心路径

9.1 与 Active Set 的思想差异

Active Set 尝试辨认最终哪些 $s_i = 0$。Interior Point 不预先判断，先让每个不等式松弛量严格正：$s_i > 0$，再逐渐接近边界。

9.2 Log Barrier（对数障碍）

对 $Gx < d$，设 $s = d - Gx > 0$，构造

$$\boxed{\phi_\tau(x) = \tfrac{1}{2} x^{\mathsf{T}} H x + c^{\mathsf{T}} x - \tau \sum_{i=1}^{p} \log s_i, \qquad \tau > 0.} \tag{21}$$

当 $s_i \to 0^+$ 时，$-\log s_i \to +\infty$。固定 τ 可通过阻尼 Newton 求解障碍子问题，然后使 $\tau \to 0^+$ 逼近原问题。纯障碍法要求初始不等式严格可行；一般等式约束仍需单独处理。

9.3 障碍函数梯度与 Hessian

因 $s = d - Gx$,

$$\boxed{\begin{aligned} \nabla \phi_\tau(x) &= Hx + c + \tau G^{\mathsf{T}} s^{-1}, \\ \nabla^2 \phi_\tau(x) &= H + \tau G^{\mathsf{T}} \operatorname{diag}(s_i^{-2}) G. \end{aligned}} \tag{22}$$

这里 s^{-1} 为逐元素倒数。Newton 方向满足

$$\nabla^2 \phi_\tau(x)\, \Delta x = -\nabla \phi_\tau(x),$$

步长必须保证所有 $s_i > 0$，可用 fraction-to-the-boundary 和线搜索控制。

9.4 一维中心路径解析例子

考虑 $\min_x \tfrac{1}{2}(x-2)^2$，满足 $x \le 1$，真实最优点 $x^* = 1$。对数障碍为

$$\phi_\tau(x) = \tfrac{1}{2}(x-2)^2 - \tau \log(1-x), \quad x < 1.$$

令导数为零：$x - 2 + \tau/(1-x) = 0$，设 $s = 1 - x > 0$，得到 $s^2 + s - \tau = 0$，所以

$$\boxed{x(\tau) = 1 - \frac{\sqrt{1+4\tau} - 1}{2}.} \tag{23}$$

当 $\tau = 1, 0.1, 0.01, 0.001$, 分别约为 $x = 0.382, 0.9084, 0.9901, 0.9990$, 从可行域内部逼近边界 $x = 1$。

9.5 障碍函数为什么对应扰动 KKT?

障碍驻点条件为

$$Hx + c + \tau G^{\mathsf{T}} s^{-1} = 0.$$

定义 $\lambda_i = \tau / s_i > 0$，则

$$Hx + c + G^{\mathsf{T}}\lambda = 0, \qquad \boxed{s_i \lambda_i = \tau.}$$

原始 KKT 要求 $s_i\lambda_i = 0$，而障碍法用 $\tau > 0$ 进行**平滑扰动**。随着 $\tau \to 0$，逐渐恢复原始互补松弛条件。

10 Primal-Dual Interior Point：牛顿求解扰动 KKT

10.1 原始–对偶变量及残差

对 QP 引入松弛变量 $s = d - Gx$，同时优化 x、等式乘子 ν、不等式乘子 λ、松弛量 s。定义

$$r_d = Hx + c + A^{\mathsf{T}}\nu + G^{\mathsf{T}}\lambda, \qquad \text{（对偶驻点残差）} \tag{24}$$

$$r_p = Ax - b, \qquad \text{（等式原始残差）} \tag{25}$$

$$r_g = Gx + s - d, \qquad \text{（松弛等式残差）} \tag{26}$$

$$r_c = S\Lambda\mathbf{1} - \tau\mathbf{1}, \qquad \text{（扰动互补残差）} \tag{27}$$

其中 $S = \mathrm{diag}(s)$、$\Lambda = \mathrm{diag}(\lambda)$。目标是使四组残差趋于零，同时保持 $s > 0, \lambda > 0$。

10.2 Newton 线性化：原始–对偶 KKT 系统

对所有残差联立求 Newton 方向：

$$\boxed{\begin{bmatrix} H & A^{\mathsf{T}} & G^{\mathsf{T}} & 0 \\ A & 0 & 0 & 0 \\ G & 0 & 0 & I \\ 0 & 0 & S & \Lambda \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta\nu \\ \Delta\lambda \\ \Delta s \end{bmatrix} = - \begin{bmatrix} r_d \\ r_p \\ r_g \\ r_c \end{bmatrix}.} \tag{28}$$

最后一行来自

$$(s_i + \Delta s_i)(\lambda_i + \Delta\lambda_i) \approx s_i\lambda_i + \lambda_i\Delta s_i + s_i\Delta\lambda_i,$$

其中忽略了二阶小量 $\Delta s_i \Delta\lambda_i$。式 (28) 是基本 primal-dual IPM 的核心计算。

10.3 消元获得更小的线性系统

由第三、四行：

$$\Delta s = -r_g - G\Delta x,$$

$$\Delta\lambda = S^{-1}(-r_c + \Lambda r_g + \Lambda G\Delta x).$$

代入第一行，得到关于 $(\Delta x, \Delta\nu)$ 的系统

$$\boxed{\begin{bmatrix} H + G^{\mathsf{T}} S^{-1} \Lambda G & A^{\mathsf{T}} \\ A & 0 \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta\nu \end{bmatrix} = \begin{bmatrix} -r_d + G^{\mathsf{T}} S^{-1}(r_c - \Lambda r_g) \\ -r_p \end{bmatrix}}. \tag{29}$$

$S^{-1}\Lambda = \mathrm{diag}(\lambda_i / s_i)$ 为正对角矩阵。这种消元揭示了内点法为什么最终也在反复求解 KKT 结构线性系统；实际算法还须处理病态、稀疏结构及正则化。

10.4 步长和中心化参数

更新 $x \leftarrow x + \alpha\Delta x$ 等变量时，必须使 $s + \alpha\Delta s > 0$、$\lambda + \alpha\Delta\lambda > 0$。定义

$$\alpha_{\max} = \min\left\{1, \min_{\Delta s_i < 0} -\frac{s_i}{\Delta s_i}, \min_{\Delta\lambda_i < 0} -\frac{\lambda_i}{\Delta\lambda_i}\right\}. \tag{30}$$

可选择 $\alpha = \eta\alpha_{\max}$，如 $\eta = 0.99$；实际求解器也可能分别选择原始/对偶步长并额外进行线搜索。

平均互补度为 $\bar{\mu} = s^{\mathsf{T}}\lambda / p$（$p$ 为不等式数量），常取

$$\boxed{\tau = \sigma\bar{\mu}, \qquad 0 < \sigma < 1.} \tag{31}$$

这里的 σ 是中心化参数，不是约束乘子。随着迭代推进，原始残差、对偶残差和互补度应同时下降。更先进的方法还包括 Mehrotra predictor–corrector。

10.5 Infeasible Start 的含义

基本对数障碍要求 $Gx < d$。原始–对偶 IPM 可以先取任意 x, ν，再使 $s > 0$、$\lambda > 0$，允许 $Ax - b \neq 0$ 或 $Gx + s - d \neq 0$，通过迭代同时消除这些残差。这种不可行起点与完全不维护松弛变量正性不是一回事。

11 Active Set、Interior Point 与其他方法对比

比较维度	Primal Active Set	Primal-Dual Interior Point
互补条件处理	猜测 $s_i = 0$ 或 $\lambda_i = 0$	用 $s_i\lambda_i = \tau$ 近似
初始化	经典可行版本要求原始可行点	可使用 infeasible start，但保持 $s, \lambda > 0$
迭代核心	等式约束 QP + 工作集更新	扰动 KKT + Newton 系统
步长	$\min(1, \text{ratio})$	保持 $s, \lambda > 0$ 的边界步长
热启动	通常直接利用旧工作集	可以热启动，但处理较复杂
适用场景	小中规模、活跃约束变化少	大型稀疏凸优化问题
潜在问题	退化、工作集循环、约束相关	KKT 病态、障碍参数与线性求解

并不存在绝对优越的方法。还可考虑 ADMM/算子分裂（例如 OSQP 采用的思路）、增广拉格朗日和 SQP。**SQP 是非线性外层框架，内部可以调用 Active Set 或 Interior Point 的 QP 求解器**。

12 其它迭代框架：SQP、SCP 与 ADMM

12.1 SQP：非线性优化外层每次求一个 QP

设原问题为 $\min f(x)$、$h(x)=0$、$g(x)\le 0$。SQP 在 x_k 处用二次函数近似目标（或 Lagrangian）并线性化约束：

$$\boxed{\begin{aligned}\min_{p}\quad & \frac{1}{2}p^{\mathsf{T}}B_k p+\nabla f(x_k)^{\mathsf{T}}p\\ \text{s.t.}\quad & h(x_k)+J_h(x_k)p=0,\\ & g(x_k)+J_g(x_k)p\le 0.\end{aligned}}$$

由 QP Solver 求 p_k，再通过线搜索、信赖域和适当的可行性机制更新 $x_{k+1}=x_k+\alpha_k p_k$。B_k 可使用 Lagrangian Hessian 的 BFGS 近似。**外层 SQP 与内层 QP Solver 属于不同层次**，因此不应把 SQP 与 Active Set 看作互相替代的同一种算法。

12.2 Sequential Convex Programming（SCP）：局部凸化非凸约束

机器人避障约束往往是非凸的，例如二维点必须在圆形障碍物外：

$$\|p-o\|^2\ge r^2.$$

记 $\psi(p)=\|p-o\|^2$，因 ψ 为凸函数，其一阶展开是全局下界：

$$\psi(p)\ge\psi(p_k)+2(p_k-o)^{\mathsf{T}}(p-p_k).$$

因此在当前参考点 p_k 线性化后，可以施加充分保证远离障碍的仿射限制

$$\boxed{\|p_k-o\|^2+2(p_k-o)^{\mathsf{T}}(p-p_k)\ge r^2.}\tag{32}$$

该线性约束定义圆外区域的一个保守半空间，可以放入 QP。重新更新参考轨迹并重复凸化，就是 SCP 的典型思想。**重要细节：**不是对所有非凸约束随便进行一阶线性化，就一定保持原问题可行；实际还需要区分内近似/外近似，使用信赖域、罚项或可行性恢复等机制。

12.3 ADMM：用增广拉格朗日分裂变量

对于可分目标和线性耦合约束

$$\min_{x,z}\ f(x)+g(z),\qquad Ax+Bz=c,$$

定义缩放对偶变量 u 和惩罚系数 $\rho>0$。ADMM 经典迭代形式为

$$x^{k+1}=\arg\min_{x}\left[f(x)+\frac{\rho}{2}\left\|Ax+Bz^k-c+u^k\right\|^2\right],\tag{33}$$

$$z^{k+1}=\arg\min_{z}\left[g(z)+\frac{\rho}{2}\left\|Ax^{k+1}+Bz-c+u^k\right\|^2\right],\tag{34}$$

$$u^{k+1}=u^k+Ax^{k+1}+Bz^{k+1}-c.\tag{35}$$

这里省去了与优化变量无关的常数项。ADMM 将一个大问题拆为交替求解的子问题，在分布式多机器人、稀疏 MPC 和特定凸 QP 结构中具有实际价值。与内点法不同，ADMM 往往以相对较便宜的单次迭代换取更多迭代次数；高精度求解时要注意残差和参数缩放。

13 机器人建模：从物理方程到 QP

13.1 实例一：带关节限位的速度逆运动学

设当前 Jacobian 为 $J(q)$，期望任务空间速度 v_d，希望关节速度 $\dot{q}$ 尽量匹配 $J\dot{q} \approx v_d$，同时避免过大的关节运动：

$$\boxed{\begin{aligned} \min_{\dot{q}} \quad & \tfrac{1}{2}\left\|J\dot{q}-v_d\right\|^2+\tfrac{\rho}{2}\left\|\dot{q}\right\|^2 \\ \text{s.t.} \quad & \dot{q}_{\min} \le \dot{q} \le \dot{q}_{\max}. \end{aligned}} \tag{36}$$

写成标准 QP,

$$\boxed{H = J^{\mathsf{T}}J+\rho I, \quad c=-J^{\mathsf{T}}v_d, \quad G=\begin{bmatrix} I \\ -I \end{bmatrix}, \quad d=\begin{bmatrix} \dot{q}_{\max} \\ -\dot{q}_{\min} \end{bmatrix}.}$$

如果采样周期为 Δt，还要求下一步位置满足 $q_{\min} \le q+\Delta t\dot{q} \le q_{\max}$，可进一步附加

$$\frac{q_{\min}-q}{\Delta t} \le \dot{q} \le \frac{q_{\max}-q}{\Delta t}.$$

这两个速度区间需要取交集。若强制 $J\dot{q}=v_d$ 作为硬等式，在机器人奇异位形或存在关节限位时可能不可行；采用上面的软任务最小二乘可允许一定跟踪误差。

13.2 实例二：机器人全身控制 WBC

在某个已确定的接触模式和当前测量状态 $(q,\dot{q})$ 下，令

$$z=\begin{bmatrix} \ddot{q} \\ \tau \\ f_c \end{bmatrix}.$$

动力学等式

$$M(q)\ddot{q}+h(q,\dot{q})=S^{\mathsf{T}}\tau+J_c(q)^{\mathsf{T}}f_c$$

和不滑动接触的加速度条件

$$J_c(q)\ddot{q}+\dot{J}_c(q,\dot{q})\dot{q}=0$$

均为 z 的仿射等式（此时模型系数视为已知）。配合

$$\tau_{\min} \le \tau \le \tau_{\max}, \qquad |f_x| \le \mu f_z, \quad |f_y| \le \mu f_z, \quad f_z \ge 0,$$

可构造线性不等式限制。二次代价可惩罚任务空间加速度误差与力矩大小：

$$\min_{z} \ \tfrac{1}{2}\left\|J_{\text{task}}\ddot{q}+\dot{J}_{\text{task}}\dot{q}-\ddot{x}_d\right\|_W^2+\tfrac{\rho}{2}\left\|\tau\right\|^2.$$

其中 $\|v\|_W^2=v^{\mathsf{T}}Wv$。上述线性摩擦不等式为常见多面体近似；固定接触模式也不能由普通连续 QP 自动完成接触切换决策。

13.3 实例三：线性 MPC

离散系统 $x_{k+1} = A_d x_k + B_d u_k$。选择优化变量为所有未来状态/输入的堆叠向量，构造

$$\min \frac{1}{2}\sum_{k=0}^{N-1}\left[\|x_k - x_{d,k}\|_Q^2 + \|u_k\|_R^2\right] + \frac{1}{2}\|x_N - x_{d,N}\|_P^2$$

满足动力学和盒约束 $x_{\min} \le x_k \le x_{\max}$、$u_{\min} \le u_k \le u_{\max}$。若 $Q, P \succeq 0$、$R \succ 0$，这是一个凸 QP，可利用阶段间稀疏耦合加速 KKT 求解。非线性动力学与非凸碰撞约束通常使原问题成为 NLP。

13.4 实例四：SQP 为什么会反复调用 QP?

对 NLP $\min f(x)$，满足 $h(x) = 0, g(x) \le 0$，在 x_k 处以二次函数近似目标并对约束一阶线性化，构造

$$\boxed{\begin{aligned} \min_{p} \quad & \tfrac{1}{2} p^{\mathsf{T}} B_k p + \nabla f(x_k)^{\mathsf{T}} p \\ \text{s.t.} \quad & J_h(x_k) p = -h(x_k), \\ & J_g(x_k) p \le -g(x_k). \end{aligned}} \tag{37}$$

然后根据线搜索/信赖域更新 x。B_k 理想上近似 $\nabla_{xx}^2 \mathcal{L}$，可以用 BFGS 构造（实际 SQP 常需保证 QP 子问题的适当凸性）。这就连起 *BFGS* $\rightarrow$ *SQP* $\rightarrow$ *QP* 求解器的学习路径。

14 实现、数值稳定性与高频易错点

14.1 数值实现检查清单

1. **矩阵维度：**检查 $H \in \mathbb{R}^{n\times n}$、$A \in \mathbb{R}^{m\times n}$、$G \in \mathbb{R}^{p\times n}$。
2. **Hessian 正定性：**不定 Hessian 不享有凸 QP 的全局保证；零空间上的正定性可能比整体正定更关键。
3. **可行性：**区分 $Ax = b$ 不一致与等式、不等式合在一起不相容。
4. **避免显式求逆：**采用线性方程组求解；大问题利用稀疏 LDL^{T} 等分解。
5. **约束缩放：**不同物理量单位差异较大时，应考虑变量和约束缩放。
6. **停止准则：**联合检查原始可行、对偶可行、驻点、互补残差，不只看 $\|x_{k+1} - x_k\|$。
7. **结果状态：**区分最优、不可行、无界、迭代上限和数值失败。

14.2 易错点总表

常见误解	正确理解
KKT 是一种算法	KKT 是必要/充分最优性条件，算法负责逼近满足条件的解
满足 KKT 一定局部最小	非凸问题中不一定；凸问题中满足 KKT 保证全局最优
$g_i = 0$ 就必有 $\lambda_i > 0$	允许 $g_i = 0, \lambda_i = 0$，属于退化情况
QP 的 Hessian 必须正定	标准 QP 可以非凸；凸 QP 只要求半正定
QP 的二次约束也算标准 QP	二次约束一般属于 QCQP
Active Set 任意点都可启动	原始可行 Active Set 需要可行初始点，其他变体另论
Active Set 的 $\alpha = 1$ 是经验值	精确工作集 QP 给出沿方向的最优步长 1
找到 $p = 0$ 就可以停止	还须检查有效不等式约束乘子非负
内点法所有迭代的 x 必须可行	基本障碍需要；primal-dual infeasible start 可暂有非零原始残差
$\lambda^{\mathsf{T}} s$ 无条件是精确原始–对偶差	该简化等式需要原始可行及驻点等前提
伪逆 IK 自动满足关节限位	伪逆不会自动处理盒约束，需建模为 QP
SQP 就是一种 QP	SQP 是求解 NLP 的外层迭代，构造 QP 子问题

15 编程模板：CVXPY 验证 QP 与 KKT

下面的 Python 示例可用来核对手算结果（代码中的目标函数加回常数项 13，以对应原始目标）：

```python
import cvxpy as cp
import numpy as np

H = np.array([[2., 0.], [0., 2.]])
c = np.array([-4., -6.])
G = np.array([[1., 1.], [-1., 0.], [0., -1.]])
d = np.array([4., 0., 0.])

x = cp.Variable(2)
constraint = G @ x <= d
objective = cp.Minimize(0.5 * cp.quad_form(x, H) + c @ x + 13.)
problem = cp.Problem(objective, [constraint])
problem.solve(solver=cp.OSQP)

print("status:", problem.status)
print("x*:", x.value)
print("original objective:", problem.value)
print("multipliers:", constraint.dual_value)
# Expected approximately:
# x*=[1.5, 2.5], original objective=0.5
# multipliers=[1., 0., 0.]
```

16 练习题（从理论到机器人应用）

习题 1. 等式约束 QP： 求解 $\min \frac{1}{2}x_1^2 + x_2^2 - 2x_1 - 4x_2$，满足 $x_1 + x_2 = 2$。要求写出 H, c, A, b，用 KKT 与 Null Space 两种方法核对。

习题 2. 有效约束与乘子： 求解 $\min \frac{1}{2}(x_1 - 3)^2 + \frac{1}{2}(x_2 - 2)^2$，满足 $x_1 + x_2 \le 3$、$x_1, x_2 \ge 0$。手算 KKT、判断有效约束及乘子。

习题 3. Phase I： 针对 $A = \begin{bmatrix} 1 & 1 \\ 2 & 2 \end{bmatrix}$、$b = (1, 3)^\mathsf{T}$，判断等式是否一致；如不一致，解释为什么给不等式增设统一松弛 t 无法修复。

习题 4. Active Set： 对例题 (15) 从 $(1, 1)$ 出发，手算方向 p、阻挡约束与 Ratio Test，直到满足 KKT。

习题 5. 步长证明： 利用工作集 QP 的 KKT 方程证明 $p \neq 0$ 时 $\phi'(\alpha) = (\alpha - 1)p^\mathsf{T}Hp$；解释为什么不能任意固定 $\alpha = 0.5$。

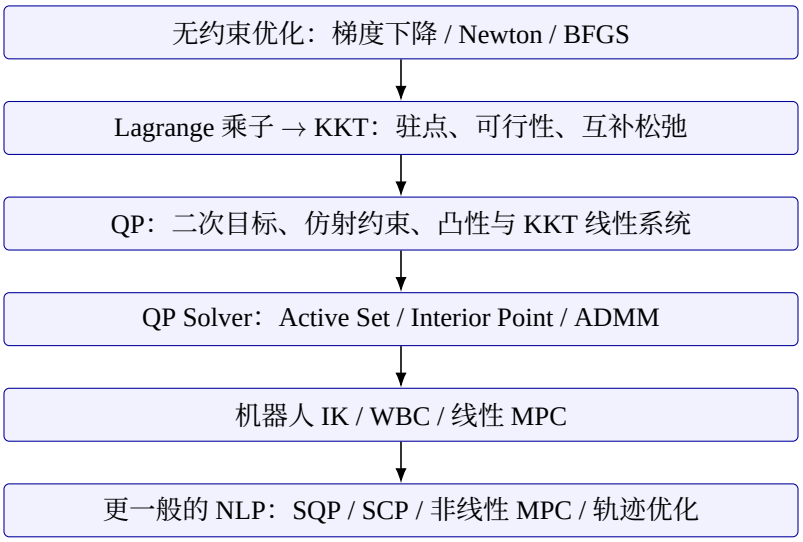
习题 6. 中心路径： 对 $\min \frac{1}{2}(x - 2)^2$、$x \le 1$，推导 $x(\tau)$ 并比较 $\tau = 1, 0.1, 0.01$ 时的松弛量和乘子。

习题 7. 原始–对偶 IPM： 从 $G\Delta x + \Delta s = -r_g$ 与 $\Lambda\Delta s + S\Delta\lambda = -r_c$ 推导式 (29) 的 Schur 消元结果。

习题 8. 受限 IK： 令 $J = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}$、$v_d = (2, 1)^\mathsf{T}$，关节速度 $-1 \le \dot{q}_i \le 1$。构建 $\frac{1}{2}\|J\dot{q} - v_d\|^2 + \frac{0.01}{2}\|\dot{q}\|^2$ 的标准 QP，并用代码验证约束和乘子。

习题 9. MPC 建模： 标量系统 $x_{k+1} = ax_k + bu_k$，预测时域 $N = 3$。把状态与控制堆叠为决策变量，显式写出块稀疏的动力学等式与二次代价 Hessian。

17 最后的知识脉络



要点： 最值得牢牢记住： (1) $\nabla_x \mathcal{L} = 0$ 是驻点条件； (2) $s_i\lambda_i = 0$ 是不等式 QP 的关键难点；(3) Active Set 通过工作集处理互补条件； (4) Interior Point 通过 $s_i\lambda_i = \tau \to 0$ 处理互补条件；(5) 二者核心计算都归结为结构化线性方程组。