

机器人数值优化算法笔记

目录

1 数值优化概述	4
2 线性最小二乘法	5
2.1 问题定义	5
2.2 正规方程	5
2.3 几何意义	6
2.4 常见求解方式	7
3 非线性最小二乘法	7
3.1 问题定义	7
3.2 残差线性化	8
4 Newton 法	9
4.1 基本思想	9
4.2 优缺点	10
5 Gauss–Newton 与 Newton 法的关系	10
6 Levenberg–Marquardt 方法	11
6.1 基本形式	11
6.2 与 Gauss–Newton 和梯度下降的关系	12
6.3 阻尼作用	13
7 Trust Region 方法	13

7.1	基本思想	13
7.2	模型预测与真实下降	13
7.3	Trust Region 与 LM 的关系	14
8	Line Search	15
8.1	基本思想	15
8.2	下降方向	16
8.3	Backtracking Line Search	16
8.4	Armijo 条件	16
8.5	Wolfe 条件	17
8.6	与 Trust Region 的区别	17
9	BFGS	18
9.1	拟 Newton 思想	18
9.2	BFGS Hessian 更新	18
9.3	逆 Hessian 更新	19
9.4	正定性	19
9.5	BFGS 与 Gauss–Newton 的区别	20
10	L-BFGS	20
10.1	动机	20
10.2	Two-loop Recursion	21
10.3	Two-loop Recursion 伪代码	22
10.4	BFGS 与 L-BFGS 对比	23
11	Line Search 与 Trust Region 的统一理解	23
11.1	Line Search	23
11.2	Trust Region	23
11.3	区别	24
12	各种算法的关系	24
12.1	Gradient Descent	24

12.2 Newton	24
12.3 Gauss-Newton	24
12.4 LM	25
12.5 BFGS	25
12.6 L-BFGS	25
13 算法对比总结	26
14 机器人中的典型优化结构	26
15 机器人位姿优化与李群	27
16 核心知识总结	28

1 数值优化概述

机器人中的大量问题最终都可以写成优化问题。例如：

- SLAM 与 Bundle Adjustment；
- 相机标定与手眼标定；
- 点云配准；
- 机器人状态估计；
- 轨迹优化；
- MPC；
- 系统辨识；
- 机器人动力学参数估计。

一般无约束优化问题写成

$$\min_{\mathbf{x}} f(\mathbf{x}), \quad (1)$$

其中

$$\mathbf{x} \in \mathbb{R}^n$$

为待优化变量， $f(\mathbf{x})$ 为目标函数。

数值优化算法通常通过迭代形式求解：

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \Delta \mathbf{x}_k. \quad (2)$$

因此，一个优化算法最核心的问题是：

如何计算当前迭代的更新量 $\Delta \mathbf{x}_k$

(3)

常见算法可大致分为：

- 一阶方法：Gradient Descent；
- 二阶方法：Newton；

- 拟二阶方法：BFGS、L-BFGS；
- 最小二乘专用方法：Gauss–Newton、LM；
- 全局化策略：Line Search、Trust Region。

2 线性最小二乘法

2.1 问题定义

考虑超定线性方程组

$$A\mathbf{x} = \mathbf{b}, \quad (4)$$

其中

$$A \in \mathbb{R}^{m \times n}, \quad m > n.$$

由于测量噪声或模型误差，通常不存在严格满足

$$A\mathbf{x} = \mathbf{b}$$

的解。

因此定义残差

$$\mathbf{r} = A\mathbf{x} - \mathbf{b}, \quad (5)$$

并希望残差的二范数最小：

$$\boxed{\min_{\mathbf{x}} \frac{1}{2} \|A\mathbf{x} - \mathbf{b}\|_2^2} \quad (6)$$

这就是线性最小二乘问题。

2.2 正规方程

定义目标函数

$$f(\mathbf{x}) = \frac{1}{2} (A\mathbf{x} - \mathbf{b})^T (A\mathbf{x} - \mathbf{b}). \quad (7)$$

展开可得

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T A^T A \mathbf{x} - \mathbf{b}^T A \mathbf{x} + \frac{1}{2} \mathbf{b}^T \mathbf{b}. \quad (8)$$

其梯度为

$$\nabla f(\mathbf{x}) = A^T (A \mathbf{x} - \mathbf{b}). \quad (9)$$

令

$$\nabla f(\mathbf{x}) = 0,$$

得到正规方程

$$\boxed{A^T A \mathbf{x} = A^T \mathbf{b}} \quad (10)$$

若 A 列满秩，则 $A^T A$ 正定，因此最小二乘解唯一：

$$\mathbf{x}^* = (A^T A)^{-1} A^T \mathbf{b}. \quad (11)$$

实际计算中通常不显式求逆，而是求解

$$A^T A \mathbf{x} = A^T \mathbf{b}. \quad (12)$$

2.3 几何意义

最优解满足

$$A^T (A \mathbf{x}^* - \mathbf{b}) = 0. \quad (13)$$

即

$$A^T \mathbf{r} = 0. \quad (14)$$

因此残差 $\mathbf{r}$ 与 A 的所有列向量正交。

换句话说，

$$A \mathbf{x}^* \quad (15)$$

是 $\mathbf{b}$ 在 A 的列空间上的正交投影。

2.4 常见求解方式

线性最小二乘可以通过以下方法求解：

1. 正规方程：

$$A^T A \mathbf{x} = A^T \mathbf{b}$$

2. QR 分解：

$$A = QR$$

3. SVD：

$$A = U \Sigma V^T$$

4. Cholesky 分解正规方程：

$$A^T A = LL^T.$$

需要注意：

$$\kappa(A^T A) = \kappa(A)^2, \quad (16)$$

因此构造正规方程会放大条件数。

数值稳定性通常满足：

$$\text{SVD} > \text{QR} > \text{Normal Equation}.$$

但计算速度通常相反。

3 非线性最小二乘法

3.1 问题定义

设残差函数

$$\mathbf{r}(\mathbf{x}) = \begin{bmatrix} r_1(\mathbf{x}) \\ r_2(\mathbf{x}) \\ \vdots \\ r_m(\mathbf{x}) \end{bmatrix}. \quad (17)$$

非线性最小二乘问题写为

$$\min_{\mathbf{x}} F(\mathbf{x}) = \frac{1}{2} \sum_{i=1}^m r_i(\mathbf{x})^2 \quad (18)$$

或者

$$F(\mathbf{x}) = \frac{1}{2} \mathbf{r}(\mathbf{x})^T \mathbf{r}(\mathbf{x}). \quad (19)$$

与线性最小二乘不同， $\mathbf{r}(\mathbf{x})$ 是 $\mathbf{x}$ 的非线性函数。

3.2 残差线性化

在当前估计 $\mathbf{x}_k$ 附近：

$$\mathbf{x} = \mathbf{x}_k + \Delta \mathbf{x}. \quad (20)$$

对残差做一阶 Taylor 展开：

$$\mathbf{r}(\mathbf{x}_k + \Delta \mathbf{x}) \approx \mathbf{r}_k + J_k \Delta \mathbf{x}, \quad (21)$$

其中

$$J_k = \left. \frac{\partial \mathbf{r}}{\partial \mathbf{x}} \right|_{\mathbf{x}_k} \quad (22)$$

为残差 Jacobian。

于是原问题近似为：

$$\min_{\Delta \mathbf{x}} \frac{1}{2} \|\mathbf{r}_k + J_k \Delta \mathbf{x}\|^2 \quad (23)$$

这已经变成一个线性最小二乘问题。

其正规方程为

$$J_k^T J_k \Delta \mathbf{x} = -J_k^T \mathbf{r}_k \quad (24)$$

随后更新

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \Delta \mathbf{x}. \quad (25)$$

不断重复这一过程即可求解非线性最小二乘问题。

4 Newton 法

4.1 基本思想

考虑一般非线性优化问题

$$\min_{\mathbf{x}} f(\mathbf{x}). \quad (26)$$

在 $\mathbf{x}_k$ 附近进行二阶 Taylor 展开：

$$f(\mathbf{x}_k + \Delta \mathbf{x}) \approx f(\mathbf{x}_k) + \mathbf{g}_k^T \Delta \mathbf{x} + \frac{1}{2} \Delta \mathbf{x}^T H_k \Delta \mathbf{x}, \quad (27)$$

其中

$$\mathbf{g}_k = \nabla f(\mathbf{x}_k), \quad (28)$$

$$H_k = \nabla^2 f(\mathbf{x}_k). \quad (29)$$

对 $\Delta \mathbf{x}$ 求导并令其为零：

$$\mathbf{g}_k + H_k \Delta \mathbf{x} = 0. \quad (30)$$

因此 Newton step 满足

$$\boxed{H_k \Delta \mathbf{x} = -\mathbf{g}_k} \quad (31)$$

即

$$\Delta \mathbf{x} = -H_k^{-1} \mathbf{g}_k. \quad (32)$$

4.2 优缺点

Newton 法优点：

- 利用了二阶曲率信息；
- 靠近极小值时具有很快的局部收敛速度；
- 对二次函数可以一步到达最优解。

缺点：

- Hessian 计算昂贵；
- Hessian 可能不正定；
- 初值不好时 Newton step 可能过大；
- 需要求解一个线性系统。

5 Gauss-Newton 与 Newton 法的关系

对于最小二乘目标：

$$F(\mathbf{x}) = \frac{1}{2} \sum_i r_i(\mathbf{x})^2. \quad (33)$$

其梯度为

$$\boxed{\nabla F = J^T \mathbf{r}} \quad (34)$$

精确 Hessian 为

$$\boxed{\nabla^2 F = J^T J + \sum_i r_i \nabla^2 r_i} \quad (35)$$

Newton 法需要完整 Hessian：

$$\left(J^T J + \sum_i r_i \nabla^2 r_i \right) \Delta \mathbf{x} = -J^T \mathbf{r}. \quad (36)$$

Gauss-Newton 忽略第二项：

$$\sum_i r_i \nabla^2 r_i. \quad (37)$$

因此采用 Hessian 近似：

$$\boxed{H_{\text{GN}} = J^T J} \quad (38)$$

得到：

$$\boxed{J^T J \Delta \mathbf{x} = -J^T \mathbf{r}} \quad (39)$$

Gauss-Newton 可以理解为：

$$\boxed{\text{针对最小二乘问题的近似 Newton 法}} \quad (40)$$

当残差较小时：

$$r_i \approx 0, \quad (41)$$

有

$$\sum_i r_i \nabla^2 r_i \approx 0, \quad (42)$$

因此

$$H_{\text{Newton}} \approx H_{\text{GN}}. \quad (43)$$

6 Levenberg-Marquardt 方法

6.1 基本形式

Gauss-Newton 方程为：

$$J^T J \Delta \mathbf{x} = -J^T \mathbf{r}. \quad (44)$$

若 $J^T J$ 病态或接近奇异，则可能得到很大的更新量。

LM 方法增加阻尼项：

$$\boxed{(J^T J + \lambda I) \Delta \mathbf{x} = -J^T \mathbf{r}} \quad (45)$$

其中

$$\lambda > 0$$

为 damping parameter。

6.2 与 Gauss–Newton 和梯度下降的关系

当

$$\lambda \rightarrow 0, \quad (46)$$

有

$$J^T J + \lambda I \approx J^T J, \quad (47)$$

因此 LM 接近 Gauss–Newton。

当 λ 很大时：

$$J^T J + \lambda I \approx \lambda I. \quad (48)$$

因此：

$$\Delta \mathbf{x} \approx -\frac{1}{\lambda} J^T \mathbf{r}. \quad (49)$$

由于

$$J^T \mathbf{r} = \nabla F,$$

所以：

$$\boxed{\Delta \mathbf{x} \approx -\alpha \nabla F} \quad (50)$$

即接近梯度下降。

因此 LM 可以理解为：

$$\boxed{\text{在 Gauss-Newton 与 Gradient Descent 之间切换}} \quad (51)$$

6.3 阻尼作用

增加 λI 有以下作用：

- 改善 $J^T J$ 的条件数；
- 减小过大的更新步长；
- 在初值较差时增强算法稳定性；
- 使矩阵更接近正定。

7 Trust Region 方法

7.1 基本思想

在当前点 $\mathbf{x}_k$ 附近构造局部二次模型：

$$m_k(\mathbf{p}) = f(\mathbf{x}_k) + \mathbf{g}_k^T \mathbf{p} + \frac{1}{2} \mathbf{p}^T B_k \mathbf{p}. \quad (52)$$

由于 Taylor 近似只在当前点附近可信，因此限制：

$$\boxed{\|\mathbf{p}\| \leq \Delta_k} \quad (53)$$

其中 Δ_k 为 trust-region radius。

于是求解子问题：

$$\boxed{\min_{\mathbf{p}} m_k(\mathbf{p}) \quad \text{s.t.} \quad \|\mathbf{p}\| \leq \Delta_k} \quad (54)$$

7.2 模型预测与真实下降

局部模型预测下降量：

$$\text{pred}_k = m_k(0) - m_k(\mathbf{p}_k). \quad (55)$$

真实函数下降量：

$$\text{ared}_k = f(\mathbf{x}_k) - f(\mathbf{x}_k + \mathbf{p}_k). \quad (56)$$

定义比值：

$$\rho_k = \frac{f(\mathbf{x}_k) - f(\mathbf{x}_k + \mathbf{p}_k)}{m_k(0) - m_k(\mathbf{p}_k)} \quad (57)$$

ρ_k 衡量局部模型预测的准确程度。

若：

$$\rho_k \approx 1,$$

说明模型可信，可扩大 trust region。

若：

$$\rho_k \approx 0,$$

说明模型预测不准确，应缩小 trust region。

若：

$$\rho_k < 0,$$

说明实际目标函数反而变大，一般拒绝该更新，并缩小 trust region。

7.3 Trust Region 与 LM 的关系

对于非线性最小二乘：

$$\min_{\mathbf{p}} \frac{1}{2} \|\mathbf{r} + J\mathbf{p}\|^2 \quad (58)$$

并限制：

$$\|\mathbf{p}\| \leq \Delta. \quad (59)$$

其 Lagrangian 为：

$$\mathcal{L} = \frac{1}{2} \|\mathbf{r} + J\mathbf{p}\|^2 + \frac{\lambda}{2} (\mathbf{p}^T \mathbf{p} - \Delta^2). \quad (60)$$

对 $\mathbf{p}$ 求导：

$$J^T(\mathbf{r} + J\mathbf{p}) + \lambda\mathbf{p} = 0. \quad (61)$$

因此：

$$\boxed{(J^T J + \lambda I)\mathbf{p} = -J^T \mathbf{r}} \quad (62)$$

这正是 LM 方程。

因此 LM 与 Trust Region 存在密切联系。

8 Line Search

8.1 基本思想

Line Search 的思想是：

$$\boxed{\text{先确定搜索方向，再决定沿该方向走多远}} \quad (63)$$

设当前搜索方向为

$$\mathbf{p}_k.$$

更新：

$$\boxed{\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{p}_k} \quad (64)$$

其中 $\alpha_k > 0$ 为步长。

定义一维函数：

$$\phi(\alpha) = f(\mathbf{x}_k + \alpha \mathbf{p}_k). \quad (65)$$

精确线搜索希望求：

$$\alpha_k = \arg \min_{\alpha > 0} \phi(\alpha). \quad (66)$$

但实际中通常采用非精确线搜索。

8.2 下降方向

若

$$\boxed{\nabla f(\mathbf{x}_k)^T \mathbf{p}_k < 0} \quad (67)$$

则 $\mathbf{p}_k$ 称为下降方向。

例如 Gradient Descent:

$$\mathbf{p}_k = -\nabla f(\mathbf{x}_k), \quad (68)$$

此时

$$\nabla f^T \mathbf{p}_k = -\|\nabla f\|^2 < 0. \quad (69)$$

8.3 Backtracking Line Search

初始化:

$$\alpha = 1. \quad (70)$$

若当前步长不满足充分下降条件, 则执行:

$$\alpha \leftarrow \rho \alpha, \quad 0 < \rho < 1. \quad (71)$$

例如:

$$1 \rightarrow 0.5 \rightarrow 0.25 \rightarrow 0.125 \rightarrow \dots$$

8.4 Armijo 条件

Armijo 条件:

$$\boxed{f(\mathbf{x} + \alpha \mathbf{p}) \leq f(\mathbf{x}) + c_1 \alpha \nabla f(\mathbf{x})^T \mathbf{p}} \quad (72)$$

其中

$$0 < c_1 < 1.$$

它要求实际下降至少达到局部一阶模型预测下降的一定比例。

8.5 Wolfe 条件

第一条为 Armijo 条件：

$$f(\mathbf{x} + \alpha \mathbf{p}) \leq f(\mathbf{x}) + c_1 \alpha \nabla f(\mathbf{x})^T \mathbf{p}. \quad (73)$$

第二条为曲率条件：

$$\nabla f(\mathbf{x} + \alpha \mathbf{p})^T \mathbf{p} \geq c_2 \nabla f(\mathbf{x})^T \mathbf{p}, \quad (74)$$

其中

$$0 < c_1 < c_2 < 1.$$

Strong Wolfe 条件写成：

$$\boxed{|\nabla f(\mathbf{x} + \alpha \mathbf{p})^T \mathbf{p}| \leq c_2 |\nabla f(\mathbf{x})^T \mathbf{p}|} \quad (75)$$

8.6 与 Trust Region 的区别

Line Search：

$$\boxed{\text{先决定方向 } \mathbf{p}, \text{ 再寻找步长 } \alpha}$$

Trust Region：

$$\boxed{\text{先限制允许搜索的区域, 再同时寻找方向和长度}}$$

二者都是局部优化中的 globalization strategy，但并不保证找到全局最优解。

9 BFGS

9.1 拟 Newton 思想

Newton 法需要 Hessian:

$$\nabla^2 f(\mathbf{x}). \quad (76)$$

BFGS 不直接计算 Hessian, 而是通过迭代过程中观察到的梯度变化估计 Hessian。

定义:

$$\mathbf{s}_k = \mathbf{x}_{k+1} - \mathbf{x}_k \quad (77)$$

以及

$$\mathbf{y}_k = \mathbf{g}_{k+1} - \mathbf{g}_k \quad (78)$$

其中

$$\mathbf{g}_k = \nabla f(\mathbf{x}_k).$$

由梯度 Taylor 展开:

$$\mathbf{g}_{k+1} \approx \mathbf{g}_k + H_k \mathbf{s}_k. \quad (79)$$

因此:

$$\mathbf{y}_k \approx H_k \mathbf{s}_k \quad (80)$$

于是希望新的 Hessian 近似 B_{k+1} 满足:

$$B_{k+1} \mathbf{s}_k = \mathbf{y}_k \quad (81)$$

这称为 secant equation。

9.2 BFGS Hessian 更新

BFGS Hessian 近似更新公式:

$$B_{k+1} = B_k - \frac{B_k \mathbf{s}_k \mathbf{s}_k^T B_k}{\mathbf{s}_k^T B_k \mathbf{s}_k} + \frac{\mathbf{y}_k \mathbf{y}_k^T}{\mathbf{y}_k^T \mathbf{s}_k} \quad (82)$$

9.3 逆 Hessian 更新

实际中经常直接维护：

$$H_k \approx (\nabla^2 f)^{-1}. \quad (83)$$

定义：

$$\rho_k = \frac{1}{\mathbf{y}_k^T \mathbf{s}_k}. \quad (84)$$

则：

$$H_{k+1} = (I - \rho_k \mathbf{s}_k \mathbf{y}_k^T) H_k (I - \rho_k \mathbf{y}_k \mathbf{s}_k^T) + \rho_k \mathbf{s}_k \mathbf{s}_k^T \quad (85)$$

搜索方向：

$$\mathbf{p}_k = -H_k \mathbf{g}_k \quad (86)$$

然后利用 Line Search 选择 α_k ：

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{p}_k. \quad (87)$$

9.4 正定性

若

$$H_k \succ 0 \quad (88)$$

且满足曲率条件

$$\mathbf{y}_k^T \mathbf{s}_k > 0 \quad (89)$$

则 BFGS 更新后的矩阵仍保持正定。

因此 BFGS 经常与 Wolfe Line Search 配合使用。

9.5 BFGS 与 Gauss–Newton 的区别

Gauss–Newton 利用的是：

$$\boxed{\text{最小二乘问题结构}} \quad (90)$$

即：

$$H \approx J^T J. \quad (91)$$

BFGS 利用的是：

$$\boxed{\text{优化过程中历史梯度的变化}} \quad (92)$$

即通过 $(\mathbf{s}_k, \mathbf{y}_k)$ 逐渐学习 Hessian。

10 L-BFGS

10.1 动机

标准 BFGS 需要显式保存

$$H_k \in \mathbb{R}^{n \times n}. \quad (93)$$

因此存储复杂度为：

$$O(n^2). \quad (94)$$

当状态维数很大时无法接受。

L-BFGS，即 Limited-memory BFGS，不保存完整 H_k ，只保存最近 m 组：

$$(\mathbf{s}_i, \mathbf{y}_i). \quad (95)$$

因此内存复杂度下降为：

$$\boxed{O(mn)} \quad (96)$$

通常

$$m = 5 \sim 20.$$

10.2 Two-loop Recursion

L-BFGS 的目标是计算：

$$H_k \mathbf{g}_k \tag{97}$$

而不显式构造 H_k 。

首先令：

$$\mathbf{q} = \mathbf{g}_k. \tag{98}$$

第一轮循环，从最新历史到最旧历史：

$$i = k - 1, k - 2, \dots, k - m. \tag{99}$$

计算：

$$\rho_i = \frac{1}{\mathbf{y}_i^T \mathbf{s}_i}, \tag{100}$$

$$\alpha_i = \rho_i \mathbf{s}_i^T \mathbf{q}, \tag{101}$$

然后：

$$\boxed{\mathbf{q} \leftarrow \mathbf{q} - \alpha_i \mathbf{y}_i} \tag{102}$$

第一轮结束后，使用初始逆 Hessian 近似：

$$H_k^{(0)} = \gamma_k I. \tag{103}$$

常用：

$$\boxed{\gamma_k = \frac{\mathbf{s}_{k-1}^T \mathbf{y}_{k-1}}{\mathbf{y}_{k-1}^T \mathbf{y}_{k-1}}} \tag{104}$$

令：

$$\mathbf{r} = H_k^{(0)} \mathbf{q}. \quad (105)$$

第二轮循环，从最旧历史到最新历史：

$$i = k - m, \dots, k - 1. \quad (106)$$

计算：

$$\beta_i = \rho_i \mathbf{y}_i^T \mathbf{r}, \quad (107)$$

然后：

$$\boxed{\mathbf{r} \leftarrow \mathbf{r} + \mathbf{s}_i(\alpha_i - \beta_i)} \quad (108)$$

最终：

$$\boxed{\mathbf{r} = H_k \mathbf{g}_k} \quad (109)$$

因此搜索方向：

$$\boxed{\mathbf{p}_k = -\mathbf{r}} \quad (110)$$

10.3 Two-loop Recursion 伪代码

```

q = g_k

for i = k-1 down to k-m:
    rho_i = 1 / (y_i^T s_i)
    alpha_i = rho_i * s_i^T q
    q = q - alpha_i * y_i

r = H0 * q

for i = k-m to k-1:
    beta_i = rho_i * y_i^T r
    r = r + s_i * (alpha_i - beta_i)

p_k = -r

```

第一轮从新到旧，第二轮从旧到新，因此称为 two-loop recursion。

10.4 BFGS 与 L-BFGS 对比

	BFGS	L-BFGS
Hessian inverse	显式存储	不显式存储
历史信息	融合到完整矩阵	最近 m 组 (s, y)
内存复杂度	$O(n^2)$	$O(mn)$
方向计算	$-H_k g_k$	Two-loop recursion
适合问题规模	中小型	大规模

11 Line Search 与 Trust Region 的统一理解

两者都是为了增强局部优化算法的稳定性。

11.1 Line Search

给定搜索方向：

$$\mathbf{p}_k, \quad (111)$$

寻找：

$$\alpha_k. \quad (112)$$

因此：

$$\boxed{\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{p}_k} \quad (113)$$

核心问题：

$$\boxed{\text{沿这个方向走多远?}} \quad (114)$$

11.2 Trust Region

给定半径：

$$\Delta_k, \quad (115)$$

直接求：

$$\boxed{\min_{\mathbf{p}} m_k(\mathbf{p}) \quad \text{s.t.} \quad \|\mathbf{p}\| \leq \Delta_k} \quad (116)$$

核心问题：

$$\boxed{\text{在可信区域内，往哪个方向、走多远最好？}} \quad (117)$$

11.3 区别

	Line Search	Trust Region
先确定	搜索方向	搜索区域
再确定	步长	完整更新向量
核心参数	α	Δ
搜索空间	一条直线	一个局部区域

12 各种算法的关系

12.1 Gradient Descent

$$\mathbf{p} = -\nabla f. \quad (118)$$

只使用一阶信息。

12.2 Newton

$$H\mathbf{p} = -\mathbf{g}. \quad (119)$$

使用精确 Hessian。

12.3 Gauss–Newton

适用于最小二乘：

$$\boxed{J^T J \mathbf{p} = -J^T \mathbf{r}} \quad (120)$$

使用：

$$H \approx J^T J. \quad (121)$$

12.4 LM

$$\boxed{(J^T J + \lambda I) \mathbf{p} = -J^T \mathbf{r}} \quad (122)$$

可以理解为带阻尼的 Gauss-Newton。

12.5 BFGS

$$\boxed{\mathbf{p} = -H_k \mathbf{g}} \quad (123)$$

其中 H_k 由历史梯度变化逐渐估计。

12.6 L-BFGS

不显式存储 H_k ，利用最近若干组：

$$(\mathbf{s}_i, \mathbf{y}_i) \quad (124)$$

通过 two-loop recursion 计算：

$$H_k \mathbf{g}. \quad (125)$$

13 算法对比总结

算法		使用的信息	是否专用于最小二乘	主要特点
Gradient descent	De-	Gradient	否	简单稳定，但收敛较慢
Newton		Gradient + Hessian	否	二阶收敛快，但 Hessian 计算昂贵
Gauss-Newton		Residual + Jacobian	是	利用 $J^T J$ 近似 Hessian
LM		Residual + Jacobian	是	GN 与梯度下降之间折中
BFGS		Gradient history	否	通过历史梯度变化估计 Hessian
L-BFGS		Gradient history	否	低内存版本 BFGS, 适合大规模问题
Line Search		Direction + objective	否	确定沿指定方向走多远
Trust Region		Local quadratic model	否	限制局部模型的可信范围

14 机器人中的典型优化结构

机器人中的很多状态估计问题可以写成：

$$\min_{\mathbf{x}} \frac{1}{2} \sum_i \mathbf{r}_i(\mathbf{x})^T \Omega_i \mathbf{r}_i(\mathbf{x}) \quad (126)$$

其中：

- $\mathbf{x}$ ：机器人状态；
- $\mathbf{r}_i$ ：第 i 个传感器残差；
- Ω_i ：information matrix；
- $\Omega_i = \Sigma_i^{-1}$ 。

线性化：

$$\mathbf{r}(\mathbf{x} + \Delta\mathbf{x}) \approx \mathbf{r} + J\Delta\mathbf{x}. \quad (127)$$

Gauss-Newton 方程：

$$\boxed{J^T \Omega J \Delta\mathbf{x} = -J^T \Omega \mathbf{r}} \quad (128)$$

定义：

$$H = J^T \Omega J, \quad (129)$$

$$\mathbf{g} = J^T \Omega \mathbf{r}. \quad (130)$$

于是：

$$\boxed{H \Delta\mathbf{x} = -\mathbf{g}} \quad (131)$$

这是 SLAM、Bundle Adjustment、机器人标定等问题中极其常见的形式。

15 机器人位姿优化与李群

对于普通欧氏变量：

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \Delta\mathbf{x}. \quad (132)$$

但机器人位姿通常属于：

$$T \in SE(3). \quad (133)$$

不能直接写：

$$T + \Delta T. \quad (134)$$

因此通常在李代数中定义小扰动：

$$\delta\xi \in \mathbb{R}^6. \quad (135)$$

右扰动更新：

$$\boxed{T \leftarrow T \exp(\delta \boldsymbol{\xi}^\wedge)} \quad (136)$$

左扰动更新：

$$\boxed{T \leftarrow \exp(\delta \boldsymbol{\xi}^\wedge) T} \quad (137)$$

因此机器人非线性最小二乘通常形成如下流程：

$$\boxed{\text{State} \rightarrow \text{Residual} \rightarrow \text{Jacobian} \rightarrow \text{Linear System} \rightarrow \text{Increment} \rightarrow \text{State Update}} \quad (138)$$

即：

$$T \rightarrow \mathbf{r}(T) \rightarrow J \rightarrow J^T J \delta \boldsymbol{\xi} = -J^T \mathbf{r} \rightarrow \delta \boldsymbol{\xi} \rightarrow T \exp(\delta \boldsymbol{\xi}^\wedge).$$

16 核心知识总结

机器人数值优化中最重要的一条主线是：

$$\boxed{\text{非线性问题} \rightarrow \text{局部近似} \rightarrow \text{线性方程} \rightarrow \text{求增量} \rightarrow \text{更新状态}} \quad (139)$$

线性最小二乘：

$$A^T A \mathbf{x} = A^T \mathbf{b}. \quad (140)$$

Newton：

$$H \Delta \mathbf{x} = -\mathbf{g}. \quad (141)$$

Gauss-Newton：

$$J^T J \Delta \mathbf{x} = -J^T \mathbf{r}. \quad (142)$$

LM：

$$(J^T J + \lambda I) \Delta \mathbf{x} = -J^T \mathbf{r}. \quad (143)$$

BFGS:

$$\mathbf{p}_k = -H_k \mathbf{g}_k. \quad (144)$$

L-BFGS:

利用最近的 $(\mathbf{s}_i, \mathbf{y}_i)$ 隐式计算 $H_k \mathbf{g}_k$

 (145)

Line Search 解决:

给定方向后, 应该走多远?

 (146)

Trust Region 解决:

当前局部近似究竟可以信任多大的范围?

 (147)

最终, 在机器人领域中经常看到:

Lie Group + Nonlinear Least Squares + Sparse Linear Algebra

 (148)

三者共同构成 SLAM、BA、机器人状态估计和标定问题的主要数学基础。